얼마나 빨라졌고, 얼마가 들었나.

로컬 / 1대 / 동시 2대 / 동시 4대 · ESRGAN 포함

4대의 핵심 처리시간은 **5분 10.26초**로 가장 짧았습니다. 로컬 40분 31.30초 대비 **87.2% 단축**입니다. 서버 준비와 회수까지 포함한 4대 경과 시간은 10분 35.87초입니다.

측정 항목	로컬	1대	2대	4대
ESRGAN+피부 효과	37분 27.40초	15분 20.66초	8분 04.98초	3분 48.48초
최종 렌더	3분 03.90초	1분 53.90초	1분 29.87초	1분 21.47초
핵심 처리 합계	40분 31.30초	17분 14.56초	9분 35.11초	5분 10.26초
준비 완료→회수	해당 없음	18분 33.09초	11분 04.25초	7분 17.49초
임대 생성→회수	해당 없음	24분 24.74초	13분 16.15초	10분 35.87초
청구 API 표시액	전력비 미측정	$0.394	$0.324	$0.503

표의 핵심 처리 합계는 동일 작업 단계를 비교합니다. 2대·4대는 가장 느린 조각의 ESRGAN+피부 효과 시간에 연결·렌더 시간을 더했습니다. 준비·전송·회수는 별도 행입니다.

1시간 처리로 비례 환산하면

1대 25분 31.87초 / **2대** 14분 11.57초 / **4대** 7분 39.40초

실측 비율의 계산 예시이며 1시간짜리 영상을 실제 생성한 결과는 아닙니다.

Jev 추천

● Jev 이번 a033 실측에서는 속도 우선이면 4대, 표시 비용 최소화는 2대입니다. 서버가 서로 다른 1회 시험이므로 보편적인 최적 대수로 단정하지 않습니다. 다음 임대는 저장한 빠른 서버를 우선 찾고 최신 총비용을 다시 비교합니다.

기록된 실험 시작부터 마지막 결과 회수까지는 78분 52.73초였습니다. 코드 준비·실패·대화·병행 시험이 포함됩니다. 실험 자체가 이만큼의 시간을 절약했다는 뜻이 아닙니다.

02 / 화면 품질과 오디오 보존

로컬 | 1대 | 2대 | 4대



AGY 실제 표본 판정: 1대는 동등, 2대·4대는 경미한 차이입니다. 얼굴·피부 질감·글자·구도에 중대한 열화를 관찰하지 않았고 추가 수정은 불필요하다고 판정했습니다. 12개 정지 표본과 원해상도 프레임에 한정된 결과이며 전체 움직임·립싱크 검사를 뜻하지 않습니다.

대응 12프레임	평균 휘도 SSIM	평균 PSNR	RGB 평균 절대오차
1대	0.994075	41.804 dB	0.761 / 255
2대	0.991668	40.260 dB	0.835 / 255
4대	0.991671	40.258 dB	0.835 / 255

AGY Gemini 3.8 Flash Medium이 실제 첨부 파일을 열어 표본을 판정했습니다. 원응답과 view_file 열람 증거를 quality 폴더에 보존했습니다. 1대는 기존 판정을 재사용했고 2대·4대는 한 요청으로 함께 비교했습니다.

오디오 결함과 수정

최초 1대 원격 출력의 오디오가 원본보다 **5.465초 짧은 결함**을 발견했습니다. 세 원격 출력 모두 영상은 재인코딩하지 않고 기존 납품본 AAC를 결합했습니다. 전체 오디오 패킷 해시 동일, 수정 전후 영상 패킷 해시 동일을 확인했습니다.

수정 소요: 1대 0.44초, 검증 1.28초 / 2대 0.55초, 검증 1.63초 / 4대 0.50초, 검증 1.52초. 원본 AAC 추출은 공통 1회 2.19초입니다.

4대의 후반 두 표본은 +1프레임(33ms) 후보가 더 가까웠습니다. 원인 확정이나 전체 시간축 검사로 확대 해석하지 않았습니다. 전체 움직임·번쩍임·립싱크를 정지 표본만으로 보증하지 않습니다.

03 / 이 컴퓨터의 자원 절약 효과

무거운 계산은 서버가 수행했습니다. 맥에는 제어·전송과 결과 확인 작업이 남았습니다. 수치로 확인한 범위와 측정하지 못한 범위를 구분합니다.

로컬 30프레임 표본	측정값
처리 경과 시간	32.139초
프로세스 최대 RSS	794.4 MiB
MPS 드라이버 최대 할당	1.04 GiB
프로세스 CPU 누적값	8.336초 · import 등 시작 이후 누적

원격 제어 프로세스	최대 합계 RSS	안정 구간 CPU[1]	관측 구간
1대	23.6 MiB	0.080%	858.5초
2대	77.1 MiB	0.169%	91.9초
4대	203.9 MiB	0.327%	127.5초

[1] 1코어 기준, 표본 사이 프로세스 누적 CPU 시간의 증가량을 구간 길이로 나눈 값입니다. 짧게 실행돼 표본에 잡히지 않은 자식 프로세스는 제외될 수 있습니다. 계측은 임대 후 시작됐습니다.

메모리 차이를 어떻게 읽어야 하나

로컬 30프레임 표본과 원격 제어 프로세스 관측의 작업 범위가 다릅니다. 1대 관측 최대 RSS 23.6 MiB는 로컬 표본보다 약 97.0% 작지만, 이를 **맥 전체 RAM 절감률**이라고 보고하지 않습니다. 2대·4대 전송 시 프로세스 메모리가 더 커진 값도 그대로 제시했습니다.

MPS 할당량과 RSS는 통합 메모리에서 겹칠 수 있어 합산하지 않습니다. 전체 CPU·GPU에는 다른 앱의 부하가 포함됩니다. 전력량·발열·배터리·전체 시스템 부하의 절감률은 이번 시험에서 측정하지 않았습니다.

로컬에 남는 작업

명령과 상태 조회, 선택 파일 전송·회수, 원본 AAC 결합, 표본 이미지 추출·분석, PDF 작성, 비교 페이지의 4K 영상 재생은 로컬 자원을 사용합니다. 디스크·네트워크 시스템 총계도 다른 작업과 분리하지 못해 작업별 절감률을 제시하지 않았습니다.

업로더의 코드·설정·우선순위·납품 폴더는 변경하지 않았습니다. 원래 납품본도 교체하지 않았습니다.

04 / 실제 오류와 재발 방지 · 실행 단계

FFmpeg 경로 불일치

첫 1대 실행에서 Conda FFmpeg에 libx264가 없어 실패했습니다.

대응 /usr/bin/ffmpeg를 명시해 같은 임대 서버에서 복구했습니다. 이미지 digest와 실행 파일·인코더를 준비 단계에서 확인합니다.

오디오 끝부분 누락

최초 1대 출력의 오디오가 원본보다 5.465초 짧았습니다. 원격 FFmpeg의 프레임 제한 출력 경로에서 발견됐으며 세부 내부 원인은 확정하지 않았습니다.

대응 세 원격본 모두 원본 AAC를 무손실 결합했습니다. 원본과 오디오 패킷 해시 동일, 수정 전후 영상 패킷 해시 동일을 확인했습니다. 영상 프레임 수만으로 성공 처리하지 않습니다.

준비 완료 오판

pipefail과 grep -q를 함께 쓴 준비 명령이 설치 후 SIGPIPE를 낼 수 있는 구조였습니다.

대응 출력을 파일에 저장한 뒤 일반 grep으로 검사하도록 수정했습니다. 설치 성공·실행 준비·작업 완료를 별도 상태로 기록합니다.

임대 제안 만료

검색된 일부 offer는 생성 시 no_such_ask로 거절됐습니다.

대응 같은 유료 요청을 반복하지 않았습니다. 고유 label/인스턴스 목록으로 미확정 생성을 먼저 확인한 뒤, 승인 범위 안의 다른 제안으로 진행했습니다.

느린 서버 준비 대기

초기 풀에서 두 서버가 준비됐지만 세 번째 서버를 기다리다 준비 제한 600초를 넘겨 시험 전 종료했습니다.

대응 최종 시험은 필요한 2대/4대를 별도 실행기로 묶었습니다. 향후에는 실제 사용할 서버만 준비 조건에 포함하고 무진척·전체 시간 제한을 둡니다.

실패 기록은 성공 결과로 덮어쓰지 않았습니다. 실패한 준비 인스턴스의 표시 비용도 전체 실험 비용에 포함합니다.

05 / 정리·품질·서버 선택에서 주의할 점

삭제 명령 확인 누락

첫 삭제 명령은 --yes가 없어 실제 삭제가 되지 않았습니다. 초기 정리 실패와 대기 비용을 보존했습니다.

대응 확인 옵션을 지정한 Destroy 후 목록에서 인스턴스 부재를 확인했습니다. Stop으로 정리 완료 처리하지 않고 별도 볼륨도 확인합니다.

분할 결합 시 시간축

4대 출력의 후반 두 표본은 동일 번호보다 +1프레임(33ms) 후보가 로컬과 더 가까웠습니다. 전체 시간축 오류로 확정한 결과는 아닙니다.

대응 표본 차이와 한계를 공개했습니다. 향후 분할 제작은 정수 프레임 경계와 PTS 정규화를 함께 적용하고 결합 경계를 확인해야 합니다. 이번 파일에 적용 완료했다고 주장하지 않습니다.

서버별 성능 편차

동일 RTX 4090에서도 프레임 처리 속도와 피부 효과 처리시간이 달랐습니다.

대응 4대 시험의 처리시간은 가장 느린 조각 기준입니다. 후속 운용은 확인된 처리율에 따라 분할량을 배정하고 시간당 단가보다 회수까지 총비용으로 고릅니다.

로컬 부하 측정 권한

2대 자원 계측 첫 시도에서 macOS 프로세스 조회가 샌드박스에 차단됐습니다. 빈 기록은 수치로 쓰지 않았습니다.

대응 읽기 전용 계측 권한으로 다시 시작했고, 계측 시작 이전 구간은 미측정으로 남겼습니다. CPU/GPU 전체 사용량에서 다른 앱의 부하를 빼지 못한 값을 절감률로 쓰지 않습니다.

빠른 서버를 저장하고 다음 임대에서 우선 비교

machine ID	실측 처리율	당시 합산 요금
150320	3.164 fps · 831프레임	$0.490/시간
146206	3.146 fps · 416프레임	$0.678/시간
23579 / 15720	2.727 / 2.720 fps	$0.612/시간

전역 server-performance.json에 저장했습니다. 다음 임대 때 최신 계산·디스크·전송·준비·회수 비용을 반드시 비교합니다. 과거 속도·가격은 현재 재고나 성능 보장이 아니며, 서로 다른 분량에서 잰 결과입니다.

비밀 보호: API 키·SSH 개인키·.env·쿠키·NAS 인증정보를 원격에 보내지 않습니다. 공개키와 허용 목록의 필요한 코드·미디어만 사용합니다. Verified는 호스트로부터의 비밀 보호 보증이 아닙니다.

06 / 지출 장부·삭제 증거·측정 조건

현재 청구 API 표시 합계 $1.776 · 그중 성공 시험 $1.221, 별도 준비 실패 $0.555.

생성한 인스턴스 17개 모두 Destroy 후 부재 확인. 최종 조회 인스턴스 0개·별도 볼륨 0개입니다. 아래 미표시 항목을 0달러로 확정하지 않았습니다.

용도	인스턴스 ID	표시 청구액	삭제 확인
1대 완주	57380679	$0.394	완료
2대 완주	57386438	$0.123	완료
2대 완주	57386441	$0.201	완료
4대 완주	57385430	$0.134	완료
4대 완주	57385432	$0.121	완료
4대 완주	57385441	$0.135	완료
4대 완주	57385446	$0.113	완료
초기 준비	57382091	$0.044	완료
초기 4대 준비	57383165	$0.058	완료
초기 4대 준비	57383167	$0.072	완료
초기 4대 준비	57383166	$0.079	완료
대체 준비	57384534	미표시 · 미확정	완료
대체 준비	57384539	미표시 · 미확정	완료
대체 준비	57384776	미표시 · 미확정	완료
준비 시간 초과	57385063	$0.133	완료
준비 시간 초과	57385066	$0.100	완료
준비 시간 초과	57385072	$0.069	완료

조회 시점: 2026-10-24T00:16:55.288702+09:00. 이후 정산 변경 가능. 소수 세 자리 API 표시값이며 환율·카드 수수료는 미포함입니다. 이전 중간 보고의 1대 $0.348은 이후 $0.394로 갱신됐습니다.

동일 모델·FP16·2배 출력·피부 효과·편집 설정, 최종 2,011프레임을 유지했습니다. 실사 1,663프레임에 ESRGAN을 적용하고 삽화 348프레임은 재사용했습니다. GPU/호스트가 다른 구성별 1회 관측이므로 대수만의 순수 가속률이나 보편적 최적값으로 단정하지 않습니다.

● Jev 서버 선택 4판단 + 추천 1판단. 형식 오류 1건은 유효 판단에서 제외. 수치·완료·삭제는 코드/API, 실제 표본 지각은 AGY, 문서 작성·실행은 주 에이전트가 담당했습니다.

근거: Vast.ai 과금 문서 · Vast.ai 공식 CLI 안내 · Vast.ai 공식 Codex 운영 안내

원자료: final-results.json · billing-final.json · 각 state.json/cleanup.json · audio-preservation.json · quality/metrics.json · quality/compare*.raw.txt · host-resource*.jsonl. 비교 페이지와 PDF는 comparison 폴더에 저장했습니다.

07 / 4대 비용이 더 높았던 원인

4대의 평균 GPU 단가는 2대보다 약 4.8% 낮았습니다. 비용이 높아진 주원인은 4대에 각각 쌓인 과금 시간입니다. 단가만으로 대수를 선택하면 실제 비용을 잘못 예상할 수 있습니다.

청구 원장 기준	1대	2대	4대
평균 GPU 단가 / 1대·시간	$0.800	$0.627	$0.597
GPU 과금 시간 합계	28.56분	28.80분	48.42분
1대당 평균 GPU 과금 시간	28.56분	14.40분	12.11분
GPU 계산 비용	$0.381	$0.301	$0.482
디스크 비용	$0.011	$0.015	$0.014
양방향 전송 비용	$0.002	$0.008	$0.007
성공 시험 합계	$0.394	$0.324	$0.503

2대에서 4대로 늘리면 전체 GPU 과금 시간의 합이 68.1% 증가했습니다. 실제 총비용 차이 +$0.179 = GPU +$0.181, 디스크 −$0.001, 전송 −$0.001입니다.

왜 처리시간만큼 비용이 줄지 않았나

이번 실행기는 조각 처리가 끝난 서버도 최종 결합·렌더·결과 회수가 끝날 때까지 유지했습니다. 서버 수는 두 배가 됐지만 1대당 평균 과금 시간은 15.9%만 줄었습니다. 준비·대기·결합·회수 시간이 각각 남는 구조입니다.

다음 운용의 개선안

조각 결과를 로컬로 회수하고 무결성을 확인하면 필요 없는 작업 서버는 먼저 Destroy하고 최종 결합 서버만 유지합니다. 준비·대기 단계별 비용과 조기 삭제로 줄어들 금액은 아직 별도로 실측하지 않았으므로 예상 절감액을 확정하지 않습니다.

과금 시간은 제공자 청구 원장의 표시값으로, 결과 회수까지의 벽시계 경과 시간과 다릅니다. 단가는 GPU만의 산술평균이며 디스크·전송료는 별도입니다. API 소수 세 자리 반올림 값 기준입니다. 구성별 서버와 실행 조건이 다른 1회 시험입니다.

로컬 메모리 비교를 감소율로 읽기

로컬 30프레임 표본 최대 RSS 794.4 MiB 대비 원격 제어·전송 프로세스는 1대 97.0%, 2대 90.3%, 4대 74.3% 작았습니다. 측정 범위가 다른 참고 감소율이며 맥 전체 메모리·전력 절감률이 아닙니다.

● Jev 사용자 명시 승인 후 비용 근거 대조 1판단 추가: 수치·설명 정합성 supported. 이 문서는 해당 청구 원장과 코드 계산을 근거로 작성했습니다.